

SYNAPSE · 协作即压缩

带增长记忆的多智能体语义 Wyner-Ziv 通信 · 设计与执行方案

内部设计稿 · 2026-06-18

协作即压缩 (Coordination as Compression)：把”两个智能体达成可继续任务的对齐”建模为一个带可学习、随经验增长的解码端边信息的 Wyner-Ziv 编码问题；由此得到一条可测、可证伪的协作速率收缩律——并在分布漂移时回弹，使速率本身成为一个免费的传感器。

本方案历经多轮自审计与红队迭代收敛定稿：一份既能拿下竞赛国一、又能投 CCF-A 主会的完整设计、实验与执行方案。

一句话定位：别去抢”第一个把率失真用于多智能体”（已有 [arXiv:2604.09521](#) 占了静态能力角度）；去抢谁都没占的”第一个证明协作速率有一条会收缩、会回弹、还能当漂移传感器的时间律，并在真实 openEuler 系统里跑出来”。

〇、给三类读者的三句话

- **给评委**：我们做的不是”又一个省 token 的小聪明”。我们让一群智能体越合作越少说废话——每个新任务需要在链路上交换的字节，沿一条曲线下降、逼近物理下限；一旦任务类型突变，字节又会当场回弹。这条曲线我们用 eBPF 实测给你看，而且有损压缩保证不出错（带校验和）。
- **给审稿人**：我们把多智能体对齐形式化为带增长边信息的语义 Wyner-Ziv，给出可达方案与失配惩罚 Δ ，并提出一个非显然、可证伪的预测——收缩曲线会停在一个可独立测量的信息地板上。漂移回弹给出一个模型无关的分布漂移传感器。
- **给自己（工程纪律）**：一套系统，两层产出。L0 全确定性、现场能稳跑（拿竞赛分）；L1 学习层离线出曲线（成论文）。同源，不重复造轮子。

1 研究背景：多智能体协作，贵在”反复说”

1.1 问题

LLM 多智能体系统 (MAS) 正在从”单体大模型”走向”分工协作”。但协作的代价被长期低估：每多一个 agent、每多一轮交互，就要把上下文反复序列化成本文、再解析回来。在长上下文、多角色、连续任务的真实工作流里，通信开销吃掉的算力与时延，常常比任务本身还多。学界已有三条线在缓解它，但各有缺口：

路线	代表	在省什么	缺口
潜空间通信	CIPHER (2310.06272)、La- tentMAS+OBF、KV- Comm (2510.03346)	发潜表示替代文本	不可审计、要求同构、会静默损坏、 且潜载荷按字节常更大
缓存	Agentic Plan Caching (2506.14852)、语义缓 存	重复再生成的算力 (compute)	只对 重复 任务有效；命中率低则失效； 省的是”重算”，不是”重说”
共享记忆	Collaborative Memory (2505.18279)	把记忆当外挂模块	与通信各用一套机制；读写多为规则 式、静态

1.2 两个被忽略的轴

现有”通信效率”研究几乎都在问**空间轴**的问题：开销如何随 agent 数 N 增长（拓扑剪枝、Agent-Prune 2410.02506）。没有人系统地刻画**时间轴**：当一支团队跨任务累积共享经验后，单位任务的协作开销如何**随经验衰减**？它有没有下限？会不会回弹？

而最近一篇理论工作 [arXiv:2604.09521](#) 《**Semantic Rate-Distortion for Bounded Multi-Agent Communication**》已经把率失真/Wyner-Ziv 搬进多智能体通信——但它处理的是**静态**的能力异质（不同算力的 agent 需要不同的语义字母表），纯理论、无系统、无时间动力学。

这恰好把我们的位置照亮了：率失真/WZ 作为”透镜”已被学界认可（去风险），但”**边信息随经验增长** → **速率随时间收缩** → **漂移回弹**”这一整块动力学，加上真实系统的字节级实证，仍是无人区。这就是 SYNAPSE 要占的山头。

1.3 为什么现在

2025–2026 是 agent 通信的爆发窗口（C2C 2510.19995 把通信成本显式建模、Scaling Teams or Scaling Time 2604.03295 研究终身学习 MAS 的性能-时间权衡）。但它们都没回答”**协作通信速率随时间怎么走**”。窗口开着，且正在收窄——这是一个值得现在做的题。

2 核心思想：协作即压缩

2.1 直觉：老同事为什么话越来越少

新搭档时，每件事都要从头交代：”那个客户叫什么、上次为什么砍预算、模板在哪。”合作久了，你只要说一句”老规矩，把 Q3 那版改一下发客户”，对方全懂。

话变少，不是因为你把上次的话录下来重放（那是缓存），而是因为对方脑子里长出了一个能预测你意图的模型。你只需要说对方猜不到的那一点点新信息，其余他自己补全。SYNAPSE 把这件事搬到 LLM 智能体之间，并且量化它：

1. **只发”惊讶”**——发送方不发完整内容，只发接收方用自己的记忆预测不出来的残差。对方能猜到的，一个字都不发。
2. **边信息会长大**——”对方能预测的部分”随共享记忆跨任务巩固而越来越大，于是每个新任务要传的字节越来越少。这就是收缩律。

3. **有一个不可逾越的地板**——话不会变成零。每个新任务总有真正新的、谁都猜不到的信息量 $H(Y | B_\infty)$ 。这是物理下限。
4. **换了赛道，话又变多**——任务类型突变（分布漂移），老经验失效，字节数当场回弹；而且回弹发生在任务质量掉下去之前。所以”话突然变多”本身就是一个免费的、提前的”风向变了”警报。
5. **有损但保证不出错**——残差是有损压缩，万一对方猜错？每条消息附几十字节的哈希校验，对方重构完一对，不符就回退取全量。省了带宽，端到端绝不静默出错。

2.2 形式化：Wyner–Ziv 透镜 + 收缩律

设定。 N 个 agent 协作完成任务流 $\{T_1, T_2, \dots\} \sim \mathcal{D}$ 。共享记忆 $\mathcal{M}$ 是内容寻址的类型化状态库（既是通信媒介，又是持久记忆——这是 v1”突触”洞见的可落地版）。发送方要让接收方 j 复原任务相关变量 Y ； j 的边信息 $B_j = \mathcal{M}_j$ (j 可访问的记忆) + 廉价 ToM 估计。

①可达下界（WZ / Slepian–Wolf，解码端边信息）。接收方持有边信息 B_j （仅解码端）。即使发送方不观测 B_j ，无损传 Y 的可达速率为 $H(Y | B_j)$ 。这是地板。

②实用可达方案（预测残差编码）。发送方用 ToM 估计 $\hat{B}_j$ 形成预测 $\hat{Y}$ ，发残差 $Y - \hat{Y}$ ：

$$R_{\text{SYNAPSE}} = H(Y | \hat{B}_j) = \underbrace{H(Y | B_j)}_{\text{WZ 地板}} + \underbrace{\Delta}_{\text{ToM 失配惩罚}}, \quad \Delta \approx I(Y; B_j | \hat{B}_j) \geq 0.$$

诚实声明：预测残差是一个次优的 WZ 方案（不是最优分箱）。我们不重证 WZ 逆定理；我们应用并扩展它到”可学习/增长边信息 + LLM-agent”。 $\hat{B}_j = B_j$ 时 $\Delta = 0$ ； $\hat{B}_j$ 与 B_j 无关时 $\Delta = I(Y; B_j)$ （边信息红利全丢）。ToM 预测器的全部价值就是压低 Δ 。

③收缩律（头牌现象，命题）。任务 $\sim \mathcal{D}$ 分段平稳，巩固算子使记忆朝 $\mathcal{D}$ 的充分统计收敛 ($\text{KL}(\mathcal{M} \parallel \text{suff.stat}(\mathcal{D})) \downarrow$)，则期望每任务协作速率

$$\mathbb{E}_{T \sim \mathcal{D}}[H(Y | B_t)] \text{ 单调不减} \rightarrow H(Y | B_\infty) \text{ (新信息熵地板)}.$$

④非显然、可证伪的预测（让理论挣到饭钱）。

收缩曲线会停在一个可独立测量的地板 $H(Y_{\text{new}} | B_\infty)$ 。怎么独立测？给一个”全知接收方”喂入全部巩固经验，测它对新任务残差的熵——这就是预言的 plateau 高度。曲线若真停在这条线上 $\rightarrow$ 理论被验证；若停不到 $\rightarrow$ 被证伪。

⑤漂移回弹（应用，命题）。 $\mathcal{D} \rightarrow \mathcal{D}'$ ，巩固出的 B_∞ 对 $\mathcal{D}'$ 不再充分， $H(Y' | B_\infty) > H(Y | B_\infty)$ ，协作速率阶跃上升；因 agent 会”多说几句补偿”，回弹先于任务质量下降发生。

推论（可发表的应用）：协作速率是 MAS 分布漂移的一个免费、模型无关、提前的传感器——不需要标签、不需要额外探针、不需要 ground truth。

2.3 与”缓存”的本质区别（全局最关键的一刀）

这是评委和审稿人都会问的第一个问题，标准答案务必背下来：

缓存吃”时间冗余”：同一 query $\rightarrow$ 同一输出，精确前缀复用，省的是重新生成的算力 (compute)。SYNAPSE 吃”语义冗余”：跨 agent、面向全新任务，省的是为对齐而必须交换的协作比特 (coordination bits)。

两者正交可叠加。在缓存之上，SYNAPSE 仍能在新任务上继续压低跨 agent 字节——因为新任务的答案从没被缓存过，但它的结构能被长大的记忆预测。

一句话：**缓存让你”不必重算”，SYNAPSE 让你”不必重说”。**

2.4 四个贡献（从 v4 的”4 并列” 收敛到”1+1+1+1”）

	类型	内容	框架无关？
C1	现象（头牌）	协作速率收缩律 + 漂移回弹：可测曲线、可独立测的地板、漂移阶跃	是（不信 WZ 也成立）
C2	透镜（已被验证）	形式化为带增长边信息的语义 WZ，给出可达方案 + 失配惩罚 Δ ；明确区分于 2604.09521（静态能力）	—
C3	保证（部署级）	Verified Lossy Coordination : 校验和让有损语义信道端到端正确（代价 $O(\text{几十字节})$ ）	是
C4	应用（so-what）	协作速率作为模型无关的提前漂移/新颖性传感器	是

降级为机制/消融（保留但不当头牌）：言语行为决策（tell/ask/write/hold）、ToM 寻址、MDL 压缩层。

3 赛题核心要求与”咬合”自检

强制自检（来自本项目历史教训 L9）：收敛主创新后，必须逐条回扫赛题硬要求，确认每条都被覆盖、且与主创新咬合（而非孤立模块）。漏一条 = 验收红线失分。下表的 MUST 清单依据 v2/v4 整理，以官方赛题书为最终准。

3.1 硬要求 × 咬合点（MUST 清单）

#	赛题硬要求	SYNAPSE 覆盖组件	与主创新的咬合
M1	≥ 3 agent、 ≥ 3 类角色、多步复杂任务	Planner/Retriever/Executor • CodeAct/Summarizer（4 角色）	角色间的对齐就是收缩律的测量对象
M2	结构化通信 + 握手/能力发现/协议映射，禁纯文本透传	类型化消息 Schema + CNR 协商	残差句柄走结构化消息头
M3	同时支持”纯文本”与”结构化协议”模式，可复现 A/B	双模式开关 + 评测器	A/B 正是收缩律 vs 基线的对照
M4	非文本中间状态传递（embedding/向量/隐状态），说明生成/传递/接收/使用	状态交换数据平面 = 预测残差编码（见 §4.2）	★核心咬合：非文本载体就是”惊讶残差”，不是”发更大的向量”
M5	共享记忆单元（ID/来源/时间/主题/摘要等元数据）	统一记忆单元 schema	记忆 = 解码端边信息 B_j 的物理载体
M6	关键词/标签/语义检索，跨任务复用	倒排 + 向量混合检索	检索命中越多 $\rightarrow B_j$ 越大 $\rightarrow$ 速率越低（收缩的微观机制）
M7	≥ 2 组关联连续任务验证	任务族 G1/G2（见 §5.2）	关联性 = 任务间共享结构 = 收缩的前提
M8	全套统计（消息数/token/非文本字节/耗时/命中率/提升）	评测模块 + eBPF 探针	收缩曲线 = 这些统计随轮次的轨迹

#	赛题硬要求	SYNAPSE 覆盖组件	与主创新的咬合
M9	五大模块齐备、稳定 ≥ 10 轮	五模块架构（见 §4）	≥ 10 轮正好画出收缩曲线
M10	openEuler 可编译运行；交付源码/文档/视频	全栈容器化	现场 demo = 收缩-回弹仪表盘

★ **M4 是最容易被”聚焦主线”挤出视野、却最关键的一条**（L9 的原始教训就是这条被漏）。SYNAPSE 的设计让 M4 与主创新**天然咬合**：非文本中间状态传递的机制**就是**预测残差编码，不是额外贴一个”发 embedding”的模块。这既补齐验收红线，又是一个差异化加分点。

3.2 评分细则打法（100 分）

评分项	分值	打法
通信效率	25	预测残差 + 引用传递，token 与字节双降； eBPF 实测坐实
状态传递创新	20	非文本 = ”发更小的惊讶” + Verified Lossy 校验 （有损还保证正确，评委能懂其工程价值）
记忆复用	20	记忆即边信息；收缩曲线 就是 记忆复用增益的可视化证据
系统完整性	20	五模块、4 角色、CodeAct 沙箱、 ≥ 10 轮、openEuler 跑通
实验验证	15	双模式 A/B + 关联任务 + 因果消融 + 诚实 crossover （写明”何时不该用”反增可信度）

4 系统架构

4.1 五大模块（一张图看懂）

可编辑版见同目录 SYNAPSE_architecture.drawio。逻辑结构如图 1：自上而下的五层 + openEuler 底座，右侧虚线是**核心反馈环**——巩固使记忆长大、ToM 把 $\hat{B}_j$ 估得更准、残差更小，于是**协作速率**沿曲线收缩。

4.2 非文本状态传递：生成 / 传递 / 接收 / 使用（赛题 M4 点名要求）

以”Retriever $\rightarrow$ Summarizer 传递检索得到的长证据”为例：

- **生成**：Retriever 取末层隐状态摘要（或对片段编码出句向量）作为任务相关表示 Y ；用 ToM 估计 Summarizer 已能预测的部分 $\hat{Y}(\hat{B}_j)$ ；算残差 $z = Y - \hat{Y}$ 。残差是**低熵的**（只剩惊讶） $\rightarrow$ 可激进量化/稀疏化 $\rightarrow$ **字节真小**（区别于 CIPHER/KV 发全量向量）。
- **传递**：消息 = 类型化头 {action,params,capability} + **残差句柄/短码** + hash(Y)；CASD 只传 j 缺的差集。
- **接收**：Summarizer 按 CNR 协商解码（同族 $\rightarrow$ 隐状态零拷贝注入；异构 $\rightarrow$ 取该句柄的句向量/文本视图）；用 B_j 预测 + 残差**重构** $\hat{Y}$ ；**校验** hash($\hat{Y}$) = hash(Y)？不符 $\rightarrow$ ask(full)。
- **使用**：作为软前缀/检索条件继续生成，省掉”内部态 $\rightarrow$ 文本 $\rightarrow$ 内部态”往返。



图 1: SYNAPSE 系统架构：五层 + 底座，右侧虚线为“经验增长 → 速率收缩”核心反馈环。

- **诚实回退**：若残差不比文本短、或对方异构不可解码，言语行为选择器自动选文本/hold，由 eBPF 记录该 crossover。

这一节把 v1 审计 A5（“非文本常更大”）和赛题 M4 一次解决：非文本在这里不是“发更大的向量”，而是“发更小的惊讶”——这是字节级真省的关键。

4.3 L0/L1 分层（一套系统，两层产出，demo 去风险）

5 实验设计与预测花销

5.1 实验清单（每个实验都对应一个待拆的攻击）

层	内容	服务对象	稳定性
L0 零阶	接收方信念 $\approx$ 记忆视图；残差 = 记忆差集 (+ 连续表示锚点残差)；言语行为 = 规则打分 (差集大 $\rightarrow$ tell；自身缺 $\rightarrow$ ask；高价值中间态 $\rightarrow$ write；残差 $\approx 0 \rightarrow$ hold)；校验和	竞赛现场 demo	全确定性, 不依赖会抖的学习件, 不会崩
L1 学习层	轻量 ToM 预测器 (小 MLP/检索式, 重构成功率自监督)；EFE 打分器 (离线监督/bandit, 非在线 RL)；巩固器；MDL 码本；收缩律拟合	顶会论文	离线日志展示, 现场不实时跑

编号	目的	设计	预期结果 / 拆哪个攻击
E1 (头牌)	收缩律 + 地板	≥ 2 组关联连续任务、 ≥ 10 轮, 画 R (每任务跨 agent 字节) vs 累计经验; 拟合形态/拐点/地板; 全知接收方 oracle 独立测地板; 消融巩固/ToM $\rightarrow$ 收缩消失	单调收缩、停在 oracle 地板 (可证伪); 用新任务、且与缓存共存 $\rightarrow$ 证明是协作速率收缩而非答案缓存 (拆”就是缓存”)
E2	与缓存正交	缓存 on/off $\times$ SYNAPSE on/off 四象限	增益叠加 (拆”缓存已 90%”)
E3	失配惩罚 Δ	人为劣化 ToM $\rightarrow$ 看 Δ 、字节 $\uparrow$ 、校验回退率 $\uparrow$	Δ 随 ToM 质量单调 (验 §2.2 ②)
E4	正确性	注入 ToM 错误, 校验和保证端到端正确	任务正确性不被有损残差破坏 (拆”静默损坏”)
E5	成本 crossover	消息长度 $\times$ 同/异构 $\times$ 预测器开销的净收益相图 (bytes+FLOPs+latency)	给出”何时净赢/净亏”; 选择器自动选文本 (拆”字节换 FLOPs”)
E6	漂移回弹 (应用)	注入分布切换, 观察 R 回弹再收缩; 与”质量下降时刻”对齐	回弹先于质量下降 $\rightarrow$ 漂移传感器 (拆”平稳性假设”, 把局限变卖点)
E7	言语行为消融	去 ask/hold/认知项	冗余轮次与字节上升 (验认知项真有用)
E8	表示三级	隐状态/句向量/文本 diff 的省幅与适用域	同族省最多, 异构文本-diff 仍省 (拆”异构即崩”)

5.2 任务族设计 (收缩的前提是”有共享结构”)

收缩幅度取决于任务间共享结构 (这是诚实风险 R1)。因此任务族必须刻意构造共享结构, 并把”结构量 $\rightarrow$ 收缩幅度”测成一条结论曲线 (横轴用任务间互信息/主题重叠度的代理量):

- **G1 (主题深挖)**: 对主题 X 做多跳研究并产出报告 (plan $\rightarrow$ retrieve $\rightarrow$ CodeAct 计算 $\rightarrow$ summarize), 跑若干轮。
- **G2 (关联演进)**: X 的更新/对比/再分析, 复用 G1 的证据句柄 + 计划过程。度量复用带来的”少检索、少计算、少 deliberation”。
- **漂移臂**: 在 G2 中途切到与 X 弱相关的主题 X', 触发 E6 回弹。
- **对照族 (负例)**: 故意选无共享结构的任务流, 预期收缩幅度 ≈ 0 ——用它证明”收缩来自共享结构”而非系统假象。

5.3 度量（模式无关主指标 + 分量诚实并报）

- **主指标**：端到端时延与能量 (**J**)（模式无关，避免 token vs 字节”苹果比橘子”）。
- **分量**：bytes_{wire} (**eBPF 实测**) ⊕ FLOPs(ToM+ 编解码) (计数) ⊕ latency ⊕ energy (功率模型估算，标注 estimated)。
- **质量护栏**：LLM-judge / ground truth，证明”省了但不掉质量”。校验和保证正确性，质量门是双保险。

5.4 预测花销

算力预算 **source: assumed**（未与你确认硬件）。下表按”单台 24-40GB GPU + 开源同族模型 (Qwen2.5-7B/14B-Instruct, vLLM)”估算；若你有更强机器可线性缩短。此项进首个审批决策包，请你校准。

项目	估算	说明
模型	Qwen2.5-7B + 14B-Instruct（同族，可取隐状态）	同族是隐状态零拷贝的前提；异构臂用句向量/文本
任务-运行规模	~2 族 × ~80 任务 × ~10 轮 × {text, synapse} × ~6 消融 × 3 seed	≈ 1,000–1,500 次任务-运行
token 体量	≈ 50–80 M tokens（推理，全本地）	多 agent × 多轮，~50K tokens/任务-运行
GPU-小时	≈ 30–60 GPU · h （含重跑/seed）	7B 在 4090 约 2K tok/s；一遍 ~8–10h，× 重跑
ToM 预测器训练	可忽略（小 MLP/检索式，离线，CPU/分钟级）	监督信号 = 重构成功率，无需大训练
质量评审 API	≈ \$20–80 （LLM-judge，可选）	也可用同族模型自评，进一步省钱
eBPF/系统适配	工程工时，非算力	提前在 openEuler 24.03 验证工具链
总钱预算	≈ \$20–80 + 自有 GPU 电费 ；租云约 \$30–100	整个项目级，非每次实验
总墙钟	≈ 8–12 周 （M1–M5，单人/小队，含工程）	见 §6.1 里程碑

结论：这是一个”小钱 + 一台 GPU + 两三个月”就能跑出全套可证伪曲线的题——这正是它对竞赛 + 投稿双周期友好的关键（对照 v1 的在线多智能体 RL：那是算力黑洞，已在 v2 审计判死）。

6 执行计划

6.1 里程碑（M1–M5）

- 1. **M1（2 周）· 骨架**：运行时 + 类型化协议 + 双模式 + 评测器骨架；先跑通 text 基线。门禁：text 模式稳定 ≥ 10 轮。
- 2. **M2（2–3 周）· 数据平面**：CAS + mmap 隐状态 + 向量库 + CNR 协商 + 预测残差编码 + 校验和（L0 全确定性）。门禁：synapse 模式字节 $<$ text，且校验回退率可测；出 E4/E2 初值。
- 3. **M3（2–3 周）· 记忆与认知**：共享记忆 + 混合检索 + 巩固器 + **ToM 预测器（L1）**。门禁：跑出 E1 收缩曲线第一版 + oracle 地板。
- 4. **M4（2 周）· 实验闭环**：CodeAct 沙箱 + eBPF 度量 + G1/G2/漂移臂 + 全消融（E3/E5/E6/E7/E8）。门禁：E1 收缩 + E6 回弹 + E2 正交三张核心图成立。
- 5. **M5（2 周）· 交付**：源码/设计文档/部署文档/实验报告/演示视频；openEuler 复现；收缩-回弹仪表盘 demo 定版。（投稿向：补 L1 分析 + 论文初稿。）

关键路径排序原则：先把 E1（收缩 + 地板）和 E2（缓存正交）设计到可证伪、可复现，再大规模铺工程——这两个实验同时决定” 论文成不成” 和” 竞赛哇点立不立”，是命门。

6.2 风险登记册（不粉饰）

风险	等级	解法
R1 收缩幅度小（共享结构少时 $H(Y B) \approx H(Y)$ ）	高	刻意构造有共享结构的任务族；把” 结构量 $\rightarrow$ 收缩幅度” 测成结论；负例族证因果
R2 ToM 无信念 ground truth	中	不预测” 信念”，预测接收方实际重构成功率（校验和成败做自监督）
R3 WZ ” 只是类比”	中	给实用可达方案 + 两个可测命题（ Δ 、地板）+ 明说” 应用并扩展，不重证逆定理”；2604.09521 反证此透镜被学界认可
R4 能量度量繁琐	低	主报 bytes(eBPF)+latency 硬数据，energy 用功率模型估算并标 estimated
异构即崩	中	表示三级（隐状态/句向量/文本 diff）优雅降级；WZ 框架表示无关
demo 现场崩	中	L0 全确定性现场跑，L1 离线出图，不让学习件上现场
openEuler 适配	中	全栈容器化；M1 前先验证工具链

6.3 交付物清单

- **竞赛**：源码 + 设计文档 + 部署文档（openEuler 24.03 容器化）+ 实验报告（全套赛题统计 + crossover）+ 演示视频（收缩-回弹仪表盘）。
- **论文**：本方案 $\rightarrow$ idea-card $\rightarrow$ 实验协议 $\rightarrow$ 分析报告 $\rightarrow$ 顶会初稿（题目候选见附录 C）。
- **一套系统两层产出**：先交 L0 拿竞赛分与可复现实验 $\rightarrow$ 加 L1 学习层与定律分析成稿投顶会。

7 定位与新颖性（撞车窗检索结论）

检索工具：semantic-scholar + web-search-prime（2026-06-17 执行）。下列论文已逐一核到存在并确认其真实主张（除标注外）。

维度	缓存族	潜空间通信	2604.09521 语义率失真	C2C (2510.19995)	Scaling Teams/Time	SYNAPSE
省什么	重复再生成	发全量潜表示	（理论刻画字母表）	建模协作成本	性能 vs 团队/时间	跨 agent 协作速率
边信息	精确前缀	无	静态能力异质	共享心智（描述）	—	共享记忆 + ToM，随经验增长
时间动力学	命中率随 warmth	无	无	无	性能随终身学习	速率收缩 + 漂移回弹（新）
正确性	精确/近似	会静默损坏	—	—	—	有损残差 + 校验 → 正确
系统/度量	应用级	token	纯理论	时延	性能	真系统 + eBPF
与缓存	—	不正交	—	—	—	正交可叠加

与最近邻 2604.09521 的精确区分（这是 SYNAPSE 的护城河）：它做静态、纯理论、能力异质的率失真刻画；我们做动态（边信息随经验增长）、真系统、字节级实证的时间收缩 + 漂移回弹 + 校验有损 + ToM 寻址。它把透镜立了起来——正好替我们去掉”这个框架合不合法”的风险——但金矿（时间动力学 + 系统）它一寸没挖。

附录 A · 诚实声明（assumed 项 / 待核验项）

- 算力预算 source: assumed: §5.4 按单台 24-40GB GPU + Qwen2.5-7B/14B 估算，未与你确认硬件 → 进首个审批决策包。
- 赛题 MUST 清单 source: reconstructed: §3.1 依据 v2/v4 整理，以官方赛题书为最终准；提交前请逐条对官方原文。
- 待核验 novelty（投稿前必补一次定向检索）：
 - ”ToM 用于最小消息寻址”是本轮核验最弱的一条（ToM-MAS 都在追踪信念，未见用于压消息字节，但未穷尽）→ 投稿前检索 audience design / pragmatic compression / RSA × agents。
 - arXiv:2511.04235（v4 称”空间预测编码 + HRL”）本环境工具受限未独立核到域，请自查其域与是否用 RL，再决定引用措辞。
- 方法定位诚实：预测残差是次优 WZ 方案；我们不声称达到 WZ 最优，也不声称新逆定理。

附录 B · 关键参考（★ = 本轮已核到存在并确认主张）

- ★ Semantic Rate-Distortion for Bounded Multi-Agent Communication. arXiv:2604.09521（最近邻：静态能力角度，须正面区分）
- ★ Communication to Completion (C2C). arXiv:2510.19995（建模协作成本 + Alignment Factor）

- ★ Agentic Plan Caching: Test-Time Memory for Fast and Cost-Efficient LLM Agents. arXiv:2506.14852（计划缓存，须正交化区分）
- ★ Scaling Teams or Scaling Time? Memory-Enabled Lifelong Learning in LLM MAS. arXiv:2604.03295（性能-时间权衡）
- ★ Collaborative Memory: Multi-User Memory Sharing with Dynamic Access Control. arXiv:2505.18279（ICML 2025）
- Wyner–Ziv (1976) 解码端边信息有损信源编码；Slepian–Wolf (1973) 分布式无损编码（经典基底）
- CIPHER. arXiv:2310.06272 | KVComm. arXiv:2510.03346 | LatentMAS+OBF（须核 ID）
- Theory of Mind for Multi-Agent Collaboration via LLMs. EMNLP 2023 | Mutual ToM. arXiv:2409.08811
- Shared Spatial Memory Through Predictive Coding. arXiv:2511.04235（域待核）
- AgentPrune / Cut the Crap. arXiv:2410.02506（ICLR’25，空间轴 scaling 对照）

附录 C · 题目候选

- *Coordination as Compression: A Contraction Law for Multi-Agent LLM Communication with Growing Memory*
- *Speak Less as You Remember More: Verified Wyner–Ziv Coordination and a Drift Sensor for LLM Agents*
- *The Communication Contraction Law: How Shared Memory Shrinks—and Drift Rebounds—Multi-Agent LLM Bandwidth*

收敛要点：头牌从”语义 WZ”换成”协作速率时间律 + 漂移传感器”，WZ 降为可引用透镜（避开 2604.09521 的正面撞车，占据其未挖的动力学 + 系统无人区）；新增 *Verified Lossy* 命名贡献、地板可证伪预测、ToM 重构成功率自监督；*L0/L1* 分层保证竞赛稳跑、论文出曲线。